

Dokumentacja Specyfikacji Wymagań (SRS)

1. Wprowadzenie

Celem naszego projektu jest stworzenie programu, który potrafi automatycznie analizować teksty (transkrypcje) z czterech różnych filmów: Dirty Dancing, Resident Evil, Obsession oraz Titanic. Wykorzystamy do tego podstawowe metody analizy danych tekstowych. Program ma za zadanie przeczytać dialogi z tych filmów i wyciągnąć z nich ciekawe informacje, na przykład jakie są w nich główne tematy, najważniejsze słowa kluczowe oraz jakie emocje towarzyszą bohaterom.

2. Cele systemu

Nasz program ma zrealizować następujące cele:

- Analiza długich tekstów z filmów.
- Znalezienie najbardziej charakterystycznych słów dla każdego filmu przy pomocy metody TF-IDF.
- Wykrycie i pogrupowanie głównych tematów poruszanych w dialogach za pomocą algorytmu LDA.
- Zbadanie nastroju i emocji w filmach za pomocą Analizy Sentymentu.

3. Wymagania funkcjonalne

- Wczytywanie plików: Program musi umieć otworzyć pliki tekstowe z zapisanymi dialogami z 4 filmów.
- Oczyszczanie tekstu (Preprocessing): Program musi przygotować tekst do analizy, czyli usunąć z niego znaki interpunkcyjne oraz tzw. stop words.
- Analiza TF-IDF: Program musi obliczyć i wyświetlić listę słów, które najbardziej wyróżniają dany film na tle pozostałych.
- Wyszukiwanie tematów (LDA): Program musi umieć podzielić teksty na wybraną przez nas liczbę kategorii tematycznych.
- Analiza Sentymentu: Program musi oceniać, czy dany fragment tekstu ma wydźwięk pozytywny, czy negatywny.
- Wyświetlanie wyników: Program musi generować wyniki w łatwej do zrozumienia formie, takiej jak proste tabele lub wykresy.

4. Wymagania niefunkcjonalne

- Język programowania: Cały projekt zostanie napisany w języku R, z wykorzystaniem podstawowych bibliotek do analizy danych.
- Szybkość działania: Analiza wszystkich 4 filmów powinna wykonać się w czasie nie dłuższym niż kilka minut.
- Rozbudowa: Kod powinien być ułożony tak, aby w przyszłości można było łatwo dodać do analizy skrypt z piątego lub szóstego filmu.
- Język danych: Program jest przystosowany do analizy tekstów w języku angielskim.

5. Interfejsy użytkownika i wymagania dotyczące danych

- Wymagania dotyczące danych: Do programu będziemy wprowadzać standardowe pliki tekstowe z rozszerzeniem .txt
- Interfejs użytkownika: Kod programu i wygenerowane przez niego wykresy będą widoczne po wykonaniu kodu w RStudio.

6. Słownictwo dokumentacji

- Transkrypcja – Pełny zapis tekstowy wszystkich dialogów z filmu.
- TF-IDF – Metoda statystyczna, która pomaga sprawdzić, jak ważne jest konkretne słowo dla danego tekstu.
- LDA – Algorytm, który potrafi samodzielnie znaleźć podobieństwa w tekstach i ułożyć je w grupy tematyczne.
- Analiza Sentymentu – Narzędzie, które ocenia nastrój tekstu.
- Preprocessing – Etap wstępny polegający na przygotowaniu i "posprzątaniu" tekstu.

7. Przypadki użycia (use cases)

- Badanie tematyki i głównych wątków: Gdy chcemy sprawdzić, o czym tak naprawdę rozmawiają bohaterowie, wczytujemy transkrypcje do programu i uruchamiamy algorytm LDA.
- Odkrywanie unikalnego słownictwa: Kiedy chcemy zbadać, czym język w jednym filmie różni się od pozostałych, użytkownik korzysta z analizy TF-IDF.
- Śledzenie nastroju i emocji: Gdy chcemy zbadać, jaki klimat panuje w filmie, używamy analizy sentymentu.

8. Scenariusze użytkownika (user stories)

1. Jako osoba zainteresowana kinematografią program może służyć do znalezienia głównych tematów w filmach, aby móc sprawdzić, o czym tak naprawdę najczęściej rozmawiają bohaterowie i jakie ukryte wątki przewijają się w dialogach.
2. Jako reżyser, chcę przeanalizować transkrypcję, aby zobaczyć na wykresie, jaki wydźwięk emocjonalny ma wykreowana przeze mnie historia.